Лекция 13

Библиотека cuBLAS.

- Тензорные операции, произведение матриц.
- Реализация произведения матриц на основе CUDA API.
- Особенности использования библиотеки cuBLAS.
- Функции cublas<T>gemm().
- Тензорные процессоры.
- Вызовы cublas<T>gemm() с использованием тензорных процессоров.

Матричное произведение тензоров Произведение матриц

N столцов

N столцов

К столцов

```
#include <malloc.h>
#include <ctime>
#define M 1024
#define K 1024
#define N 1024
void hMultMats(double** A, double** B, double** C){
 double acc;
 for(int m=0; m < M; m++)
  for(int n=0; n< N;n++){
   acc=0.0:
   for(int k=0; k< K; k++)
    acc+=A[m][k]*B[k][n];
   C[m][n]=acc;
```

```
void hInitMats(double** A, double** B){
 for(int m=0; m < M; m++)
   for(int k=0; k<K; k++)
    A[m][k]=(double)((k+m*K)*1.0E-5);
 for(int k=0; k<K;k++)
   for(int n=0; n<N;n++)
     B[k][n]=1.0;
```

```
Int main(){
double **A, **B, **C:
 A=(double**)calloc(M, sizeof(double*));
 for(int m=0; m<M; m++)
  A[m]=(double*)calloc(K, sizeof(double));
hInitMats(A, B);
clock t start=clock();
 hMultMats(A, B, C);
clock t finish=clock();
 hMatOut(A, M, K);
 hMatOut(B, K, N);
 hMatOut(C, M, N);
```

```
/Lecture8/Lab8> ./lab8cpu
      0.00128 0.00256 0.00384 0.00512 0.0064 0.00768 0.00896
1.31072 1.312 1.31328 1.31456 1.31584 1.31712 1.3184 1.31968
9.17504 9.17632 9.1776 9.17888 9.18016 9.18144 9.18272 9.184
5.23776 5.23776 5.23776 5.23776 5.23776 5.23776 5.23776
1347.42 1347.42 1347.42 1347.42 1347.42 1347.42 1347.42 1347.42
2689.59 2689.59 2689.59 2689.59 2689.59 2689.59 2689.59 2689.59
9400.48 9400.48 9400.48 9400.48 9400.48 9400.48 9400.48
Elapsed time: 4173.59 ms
```

```
/Lecture8/Lab8> g++ lab8cpu.cpp -pg -o lab8cpu
/Lecture8/Lab8> ./lab8cpu
/Lecture8/Lab8> Is -ltr
итого 720
-rw-r--r-- 1 malkov users 1528 Mar 16 18:27 lab8cpu.cpp
-rwxr-xr-x 1 malkov users 20496 Mar 16 19:22 lab8cpu
-rw-r--r-- 1 malkov users 1023 Mar 16 19:22 gmon.out
/Lecture8/Lab8> gprof lab8cpu gmon.out > lab8cpu.prof
/Lecture8/Lab8> vim lab8cpu.prof
Flat profile:
Each sample counts as 0.01 seconds.
% cumulative self self
                          total
      secs secs calls s/call
time
                                s/call
                                              name
100.40 3.98 3.98 1 3.98 3.98 hMultMats(double**, double**, double**)
0.25 3.99 0.01 1 0.01
                                 0.01 hlnitMats(double**, double**)
```

```
#include <malloc.h>
#define M 1024
#define K 1024
#define N 1024
#define BLOCK DIM 32
  global void gMultMats(float* A, float* B, float* C){
 int n=threadIdx.x + blockIdx.x*blockDim.x;
 int m=threadldx.y + blockldx.y*blockDim.y;
 float acc=0.0;
 for(int k=0; k<K; k++)
  acc+=A[k+m*K]*B[n+k*N];
 C[n+m*N]=acc;
```

```
__global___ void glnit(float* D, int s){
  int j=threadIdx.x + blockIdx.x*blockDim.x;
  int i=threadIdx.y + blockIdx.y*blockDim.y;
  int J=blockDim.x*gridDim.x;

D[j+i*J]=s*(float)((j+i*J)*1.0E-5)+(1-s)*1.0f;
```

```
int main(){
 float *A, *B, *C;
 cudaMalloc((void**)&A, M*K*sizeof(float));
 gInit << dim 3(K/32, M/32), dim 3(32,32) >>> (A,1);
 cudaDeviceSynchronize();
 gInit << dim 3(N/32, K/32), dim 3(32,32) >>> (B,0);
 cudaDeviceSynchronize();
 cudaMemset(C, 0, M*N*sizeof(REAL));
 gMultMats<<<dim3(N/BLOCK DIM, M/BLOCK DIM),
               dim3(BLOCK DIM, BLOCK DIM)>>>(A,B,C);
 cudaDeviceSynchronize();
 hMatOut(A, M, K);
```

/Lecture8/Lab8> ./lab8gpu							
0	0.00128	0.00256	0.00384	0.00512	0.0064	0.00768	0.00896
1.31072	1.312	1.31328	1.31456	1.31584	1.31712	1.3184	1.31968
9.17504	9.17632	9.1776	9.17888	9.18016	9.18144	9.18272	9.184
////////	//////////	///////////////////////////////////////	///////////////////////////////////////	///////////	///////////////////////////////////////	//////////	////
1	1	1	1	1	1	1	1
1	1	1	1	1	1	1	1
							······ • •
	///////////	///////////	///////////	//////////	///////////	//////////	
' ' ' ' ' ' ' ' ' '	, , , , , , , , ,	, , , , , , , ,		, , , , , , , ,	///////// 5.23776	, , , , , , , ,	• • •
5.23776	5.23776	5.23776	5.23776	5.23776	. , , , , , , ,	5.23776	5.23776
5.23776 1347.42	5.23776 1347.42	5.23776 1347.42	5.23776 1347.42	5.23776 1347.42	5.23776	5.23776 1347.42	5.23776 1347.42
5.23776 1347.42	5.23776 1347.42	5.23776 1347.42	5.23776 1347.42	5.23776 1347.42	5.23776 1347.42	5.23776 1347.42	5.23776 1347.42
5.23776 1347.42 2689.59	5.23776 1347.42 2689.59	5.23776 1347.42 2689.59	5.23776 1347.42 2689.59	5.23776 1347.42 2689.59	5.23776 1347.42	5.23776 1347.42 2689.59	5.23776 1347.42 2689.59

```
/Lecture8/Lab8> nvprof ./lab8gpu

Type
Time(%) Time Calls Avg Min Max Name
GPU activities:
63.25% 3.9720ms 1 3.9720ms 3.9720ms 3.9720ms gMultMats(float*, float*)
1.90% 119.46us 2 59.728us 59.648us 59.808us gInit(float*, int)
```

3.98s*1000/3.9720=**1002.0141**

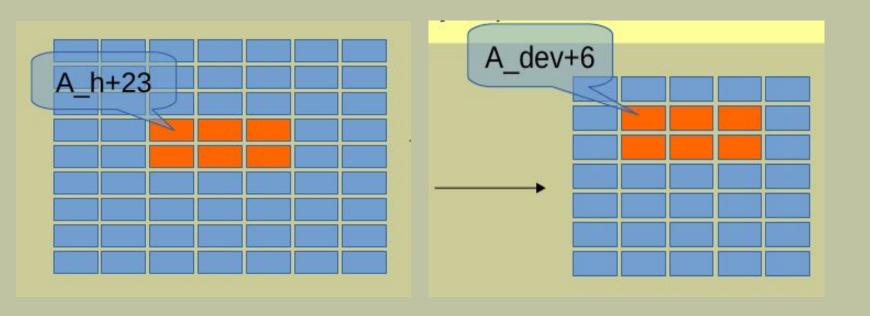
Ускорение в тысячу раз! 😲

Библиотека cuBLAS (Basic Linear Algebra Subroutines)

- Хранение по столбцам (column-major storage), совместимость с Фортраном, для копирования и инициализации матриц следует использовать специальный API.
 - Линейная индексация массивов;
- Имена функций образуются по схеме: cublas<T><function>.
 Например, cublasSgemm, тип данных float, generic/general matrix-matrix умножение плюс сложение: C=αAB+βC

Документация: https://docs.nvidia.com/cuda/cublas/#

```
int main(){
// Инициализация библиотеки CUBLAS
cublasHandle t cublas handle;
                                                         leading
cublasCreate(&cublas handle);
                                                         dimension
//Копирование матрицы с числом строк num rows и чис
столбцов //num_cols с хоста на устройство
 cublasSetMatrix(num rows, num cols, elem size, A h, Idah, A dev, Idad);
 <вызов функции cuBLAS API>
 cublasGetMatrix(num rows, num cols, elem size, A_dev, num_rows, A_h,
                                                         num rows);
 cublasDestroy(cublas handle);
```



leading dimension равно 9

leading dimension равно 7

```
void hMultMatsBlas(REAL* A, REAL* B, REAL* C){
 cublasHandle t cublas handle;
 cublasCreate(&cublas handle);
 const float alpha=1.0;
 const float beta=0.0;
// cublasSetMathMode(cublas_handle, CUBLAS_TENSOR_OP_MATH);
 cublasSgemm(cublas_handle, CUBLAS_OP_T, CUBLAS_OP_N,
               M, N, K,
               &alpha,
               A, M,
               B, K,
               &beta.
               C, M);
 cublasDestroy(cublas handle);
```

```
void hMatOutBlas(REAL* D, int I, int J){
   REAL* Dh=(REAL*)calloc(I*J, sizeof(REAL));
   cublasGetMatrix(I, J, sizeof(REAL), D, I, Dh, I);
}
```

"NVIDIA GeForce RTX 2060"

Ускорение по отношению к алгоритму на основе *CUDA API* на *GPU* 7.68.

```
~/Lecture8/Lab8blas> nvprof ./lab8blas
```

```
16.51% 516.96us 1 516.96us 516.96us 516.96us volta_sgemm_128x64_tn 3.81% 119.39us 2 59.695us 59.552us 59.839us
```

glnit(float*, int)

"GeForce GTX 1050"

```
~/WORKSHOP/PGP-2023> nvprof ./lab8blas
41.49% 1.3640ms 1 1.3640ms 1.3640ms 1.3640ms

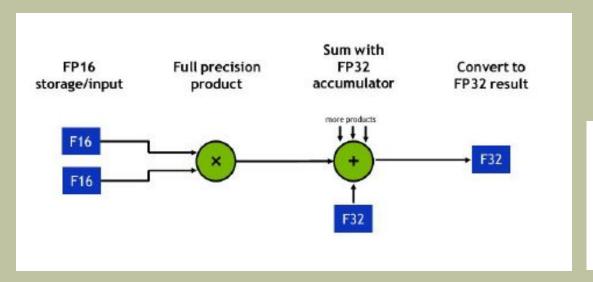
sgemm_128x128x8_NT_vec

9.28% 305.00us 2 152.50us 152.36us 152.65us

qlnit(float*, int)
```

Нейронные процессоры:

- специализированные микросхемы, "заточенные" на ускорение алгоритмов машинного обучения;
- аппаратная реализация GEMM (C=αAB+βC);
- вычисления со смешанной точностью (FP16, FP32, FP64);
- перемножение матриц размерности 4x4, 8x8, 16x16 за один такт;



GETTING STARTED WITH TENSOR CORES IN HPC Vishal Mehta, NVIDIA Super Computing, 2019 Google TPU,
Huawei Ascend 310 / Ascend 910,
NVIDIA Tensor Cores.

V100: 64 GEMM за такт, архитектура Volta (Nvidia Tesla V100), sm_70; TU100-104: архитектура Turing (Geforce RTX 20*), sm_75; A100: 256 GEMM за такт, архитектура Ampere (Geforce RTX 30*), sm_80.

WMMA, https://docs.nvidia.com/cuda/cuda-c-programming-guide/index.html#wmma; cuBLAS, https://docs.nvidia.com/cuda/cublas/;
CUTLASS, https://nvidia.github.io/cutlass/;
cuTENSOR, https://docs.nvidia.com/cuda/cutensor/;
cuDNN, https://developer.nvidia.com/cudnn;
TensorFlow, https://www.tensorflow.org/,
https://docs.nvidia.com/deeplearning/frameworks/tensorflow-user-guide/;
PvTorch, https://pytorch.org/.

- 1. CUTENSOR A CUDA Library for High-Performance Tensor Primitives, Paul Springer, November 20th 2019.
- 2. GETTING STARTED WITH TENSOR CORES IN HPC, Vishal Mehta, NVIDIASuper Computing, 2019
- CUTLASS:CUDA TEMPLATELIBRARY FOR DENSE LINEAR ALGEBRA AT ALL LEVELS AND SCALES, Jeng Bai-Cheng(Ryan), 21 Nov.
- 4. VOLTA TENSOR CORE TRAINING ORNL, August 2019.
- 5. Stefano Markidis et al. NVIDIA Tensor Core Programmability, Performance & Precision, arXiv:1803.04014 [cs.DC], (2018). https://doi.org/10.48550/arXiv.1803.04014.

Тензорные ядра не активны.

```
~/Lecture8/Lab8blas> nvprof ./lab8blas
11.63% 308.32us 1 308.32us 308.32us 308.32us
                                    volta s884gemm 128x128 ldg8 f2f tn
4.44% 117.79us 2 58.895us 58.784us 59.007us
                                    glnit(float*, int)
                                            Тензорные ядра активны.
~/Lecture8/Lab8blas> ncu --replay-mode application --metrics
sm pipe tensor cycles active.avg.pct of peak sustained active lab8blas
volta_s884gemm_128x128_ldg8_f2f_tn, 2023-Mar-20 12:29:27, Context 1, Stream 7
 Section: Command line profiler metrics
```

sm__pipe_tensor_cycles_active.avg.pct_of_peak_sustained_active % 37.90

Ускорение по отношению к алгоритму на основе *CUDA API* на *GPU* 12.9.

Потеря точности.

5.23777	5.23777	5.23777
1347.41	1347.41	1347.41
2689.56	2689.56	2689.56
9400.73	9400.73	9400.73
3 7 00.73	0 1 00.70	

```
void hMultMatsBlas(half* A, half* B, half* C){
 const half alpha=1.0;
 const half beta=0.0;
 cublasSetMathMode(cublas handle, CUBLAS TENSOR OP MATH);
 cublasHgemm(cublas handle, CUBLAS OP T, CUBLAS OP N,
               M, N, K,
               &alpha,
               A, M,
               B, K,
               &beta.
               C, M);
 cublasDestroy(cublas handle);
```

```
global void glnit(REAL* D, int s){
 D[j+i*J] = ___float2half(s*(float)((j+i*J)*1.0E-5)+(1-s)*1.0f);
int main(){
 half *A, *B, *C;
 cudaMalloc((void**)&A, M*K*sizeof(half));
 hMultMatsBlas(A,B,C);
fprintf(stdout, "%g\t", __half2float(Dh[i+j*l]));
```

```
/Lecture8/Lab8blas> nvprof ./lab8blasH
13.92% 118.59us 2 59.295us 59.231us 59.359us
                      glnit( half*, int)
11.68% 99.519us 1 99.519us 99.519us 99.519us
                      turing_h1688gemm_128x128_ldg8_stages_32x1_tn
~/Lecture8/Lab8blas> ncu --replay-mode application --metrics
sm pipe tensor cycles active.avg.pct of peak sustained active
lab8blas
turing h1688gemm 128x128 ldg8 stages 32x1 tn, 2023-Mar-20 14:42:07, Context
1. Stream 7
 Section: Command line profiler metrics
sm pipe tensor cycles active.avg.pct of peak sustained active %
                                                                  62.27
```

Тензорные ядра активны.

Потеря точности.

1344 2688	5.23828. 1344. 2688.	.1344 2688
	9392	

Ускорение по отношению к алгоритму на основе CUDA API на GPU **39.9.**

Ускорение по отношению к алгоритму на CPU 39992.36.

В сорок тысяч раз!

ЗАДАНИЕ.

Реализовать вычисление произведения матриц на GPU, используя CUDA API ("сырой код") и, отдельно, используя библиотеку *cuBLAS*. Сравнить время выполнения программ при различной размерности матриц.